Análisis Multivariado 2025-2

Análisis discriminante cuadrático

Presentado por

Cristian David Barrios Echeverri
Valery Saenz Robayo
Paula Camila Garcia Nieto

---

1 Introducción al Análisis Discriminante

El análisis discriminante es un método estadístico utilizado para clasificar elementos en diferentes grupos o poblaciones, basándose en características observables de esos elementos. Este proceso se aplica en situaciones donde, partiendo de una muestra de elementos previamente clasificados, se busca asignar nuevos elementos a uno de los grupos definidos, utilizando la información disponible sobre cada uno de ellos.

El método se fundamenta en la premisa de que los elementos provienen de dos o más poblaciones conocidas, y para cada elemento se han medido ciertas variables, cuyas distribuciones se conocen en cada población. La finalidad es asignar un nuevo elemento, cuyo conjunto de características es conocido, al grupo o población al que más probablemente pertenece.

Existen diferentes enfoques dentro del análisis discriminante. El enfoque clásico, desarrollado por Fisher, asume que las variables consideradas siguen una distribución normal multivariada. Este enfoque es óptimo bajo esa suposición. Sin embargo, si las variables no siguen una distribución normal, es posible transformarlas para que lo hagan y aplicar el método sobre las transformaciones. En casos donde las variables son tanto discretas como continuas, y la normalidad multivariante no es un supuesto realista, se pueden emplear otras técnicas adaptadas a esos casos.

El análisis discriminante es particularmente útil en aplicaciones como el diagnóstico médico, la concesión de créditos, el reconocimiento de patrones (como el reconocimiento de voz o la clasificación de imágenes), y la clasificación de textos o documentos según su autor. Además, es ampliamente utilizado en situaciones donde la información para clasificar los elementos es incompleta, costosa de obtener, o destructiva para el elemento en cuestión.

El análisis discriminante no requiere que las probabilidades a priori se conozcan exactamente; si no se conocen, se pueden tomar como iguales o proporcionales al tamaño muestral.

En resumen, el análisis discriminante proporciona los criterios y métodos necesarios para clasificar de manera eficiente nuevos elementos en categorías predefinidas, basándose en una muestra de elementos ya clasificados y en un conjunto de variables observables.

2 Análisis Discriminante Cuadrático

El Análisis Discriminante Cuadrático (QDA) es un método de clasificación supervisada que pertenece a la familia de los modelos discriminantes basados en distribución. Al igual que el Análisis Discriminante Lineal (LDA), el método parte del supuesto de que cada grupo o población sigue una distribución Normal Multivariada. Sin embargo, la diferencia esencial se presenta en el tratamiento de las matrices de covarianza de cada población.

Ambos métodos comparten varios fundamentos conceptuales, las observaciones pertenecen a una de k poblaciones previamente definidas. Se asume que cada población se distribuye normal multivariada. El objetivo es asignar una nueva observación x al grupo con mayor probabilidad posterior. La diferencia fundamental entre LDA y QDA radica en el supuesto sobre las matrices de covarianza, para el análisis discriminante cuadrático (QDA), las matrices de covarianza son diferente en cada grupo.

En consecuencia, QDA es más flexible que LDA, pues permite modelar grupos con diferentes formas, orientaciones y tamaños. Esta flexibilidad se observa en fronteras de decisión curvas o cuadráticas, lo que suele mejorar el desempeño clasificatorio cuando las matrices de covarianza difieren sustancialmente entre grupos. Pero debido a esta mayor complejidad, se requiere tamaños de muestra más grandes y puede incrementar el riesgo de sobreajuste.

Supuestos del Análisis Discriminante Cuadrático

El Análisis Discriminante Cuadrático se fundamenta en los siguientes supuestos:

1. Las observaciones provienen de una de k poblaciones o grupos bien definidos.
2. Cada población sigue una distribución Normal Multivariada:

$$X \mid G = g \sim N_p(\mu_g, \Sigma_g),$$

   donde μ_g es el vector de medias del grupo g y Σ_g es su matriz de covarianza.

3. Las matrices de covarianza difieren entre grupos:

$$\Sigma_1 \neq \Sigma_2 \neq \cdots \neq \Sigma_k.$$

   En consecuencia, la frontera de decisión no es un hiperplano como en LDA, sino una forma cuadrática (cónica, hiperbólica, elíptica).

4. Se conocen o se estiman las probabilidades a priori $\pi_g = P(G = g)$, las cuales pueden ser iguales para todos los grupos o proporcionales a su tamaño muestral.
5. Las observaciones dentro de cada grupo son independientes y se obtienen de manera aleatoria.

Bajo estos supuestos, la regla de clasificación de Bayes conduce naturalmente a un discriminante de forma cuadrática en x, lo que da origen al método de Análisis Discriminante Cuadrático.

3 Función Discriminante Cuadrática

Dado que en el Análisis Discriminante Cuadrático (QDA) cada grupo G_i posee su propia matriz de covarianza Σ_i, la función de discriminación óptima debe incorporar estas diferencias para minimizar el error de clasificación en el sentido de Bayes. Considerando k poblaciones de dimensión p, con distribuciones

$$X \mid G_i \sim N_p(\mu_\mathbf{i}, \mathbf{\Sigma_i}), \qquad i = 1, \ldots, k,$$

y probabilidades a priori $p_i = P(G_i)$.

La densidad conjunta bajo el grupo G_i es

$$f_i(\mathbf{X} \mid G_i) = \frac{1}{(2\pi)^{p/2}|\Sigma_i|^{1/2}} \exp\left\{-\frac{1}{2}(X-\mu_i)'\Sigma_i^{-1}(X-\mu_i)\right\}.$$

La regla de Bayes sugiere clasificar x en el grupo con mayor probabilidad posterior, lo cual es equivalente a maximizar:

$$\ln[p_i f_i(\mathbf{X} \mid G_i)] = \ln(p_i) - \frac{1}{2}p\ln(2\pi) - \frac{1}{2}\ln|\mathbf{\Sigma_i}| - \frac{1}{2}(\mathbf{X}-\mu_\mathbf{i})'\mathbf{\Sigma_i^{-1}}(\mathbf{X}-\mu_\mathbf{i}).$$

Para una muestra se emplea el vector de medias muestra $\mathbf{\bar{X}_i}$ y la matriz de covarianzas muestral $\mathbf{S_i}$ para cada uno de los k-grupos. El término constante $-\frac{1}{2}p\ln(2\pi)$ es común para todos los grupos y puede omitirse. Esto conduce a la función discriminante cuadrática:

$$Q_i(\mathbf{X}) = \ln(p_i) - \frac{1}{2}\ln|\mathbf{S_i}| - \frac{1}{2}(\mathbf{X}-\mathbf{\bar{X}_i})'\mathbf{S_i^{-1}}(\mathbf{X}-\mathbf{\bar{X}_i}).$$

La regla de clasificación es entonces: Asignar la observación $\mathbf{X}$ al grupo para el cual $Q_i(X)$ sea la más grande. Una regla equivalente es considerar la identidad $-Q_i(X) = Q_i(X)^*$, la cual se expresa como:

$$Q_i^*(\mathbf{X}) = \frac{1}{2}(\mathbf{X}-\mathbf{\bar{X}_i})'\mathbf{S_i}^{-1}(\mathbf{X}-\mathbf{\bar{X}_i}) + \frac{1}{2}\ln|\mathbf{S_i}| - \ln(p_i)$$

la cual produce la misma clasificación porque $Q_i^*(x) = -Q_i(x)$.

Clasificación bajo probabilidades a priori idénticas o desconocidas

Si las probabilidades a priori p_i son iguales o no se conocen, el término $ln(p_i)$ puede descartarse de la función de discriminación. Importante, para que exista S_i, se debe satisfacer que $n_i > p$, con $i = 1, ..., k$; es decir que el número de observaciones en cada grupo debe ser mayor que el número de variables. Para poblaciones multinormales con matrices de covarianzas desiguales Σ_i, la probabilidad a posteriori (bayesiana), empleando los estimadores de μ_i y Σ_i, está dada por:

$$P(G_i \mid \mathbf{X}) = \frac{p_i|\mathbf{S_i}|^{-1/2}\exp\{-12D_i^2(x)\}}{\sum_{i=1}^k p_i|\mathbf{S_i}|^{-1/2}\exp\{-12D_j^2(x)\}}$$

Donde

$$D_i^2(x) = (\mathbf{X}-\mathbf{\bar{X}_i})'\mathbf{S_i}^{-1}(\mathbf{X}-\mathbf{\bar{X}_i}).$$

Esto permite interpretar la clasificación de QDA como una competencia entre distancias cuadráticas ponderadas por la variabilidad de cada grupo y sus probabilidades a priori.

En resumen, el discriminante cuadrático es más flexible que el discriminante lineal porque permite diferencias en la forma, tamaño y orientación de las distribuciones de cada grupo. Sin embargo, esta mayor flexibilidad implica estimar más parámetros (una matriz de covarianza por grupo), lo

cual demanda tamaños de muestra más grandes y puede aumentar la variación en la regla de clasificación.

Pero, también debe tenerse en cuenta que el número de parámetros a estimar en el caso cuadrático es mucho mayor que en el caso lineal. En el caso lineal hay que estimar $Gp + \frac{p(p+1)}{2}$ y en el caso cuadrático $G\left(p + \frac{p(p+1)}{2}\right)$. Por ejemplo, con 10 variables y 4 grupos pasamos de estimar 95 parámetros en el caso lineal a 260 en el caso cuadrático. Este gran número de parámetros hace que, salvo en el caso en que tenemos muestras muy grandes, la discriminación cuadrática sea bastante inestable y, aunque las matrices de covarianzas sean muy diferentes, se obtengan con frecuencia mejores resultados con la función lineal que con la cuadrática. Un problema adicional con la función discriminante cuadrática es que es muy sensible a desviaciones de la normalidad de los datos. La evidencia disponible indica que la clasificación lineal es en estos casos más robusta. Se recomienda siempre calcular los errores de clasificación con ambas reglas utilizando validación cruzada y, en caso de que las diferencias sean muy pequeñas, quedarse con la lineal.

4 Aplicación a datos

En enología y control de calidad, cada vino—tanto tinto como blanco—posee características químicas propias que se miden rutinariamente en laboratorios como la acidez fija, la acidez volátil, el ácido cítrico, azúcares residuales, cloruros, dióxido de azufre, densidad, pH, sulfatos, alcohol.

Aunque estos valores se miden con máquinas, no siempre se tiene información clara sobre el tipo de vino (tinto o blanco), especialmente cuando se reciben lotes mezclados, se integran vinos de diferentes proveedores, se verifican fraudes o adulteraciones, se hace control de calidad sin etiquetas.

Por esto, es útil saber si solo con las características químicas podemos determinar si un vino es tinto o blanco, sin mirar la etiqueta.

Entonces, queremos construir un clasificador que, dado un vino desconocido y sus once mediciones químicas, pueda responder:

¿Este es vino tino o blanco?

El análisis discriminante busca separar grupos usando sus medias y covarianzas. En LDA (lineal) se requiere que los grupos tengan misma matriz de covarianzas y diferencias principalmente en la media.

Pero en el dataset del vino, los vinos tintos y blancos tienen variaciones químicas muy diferentes,las correlaciones internas (su forma elíptica) también son distintas y sus matrices de covarianza no son iguales.

¿Qué signifca esto en la vida real? Significa que podemos construir un sistema que recibe las mediciones químicas de un vino nuevo. Evalúa qué tan cerca está del "perfil" del vino tinto y blanco. Considera la variabilidad de cada grupo. Calcula cuál es más probable y devuelve una clasificación automática. Sin necesidad de etiquetas,color observado, metadatos,información adicional del productor.

4.1 Carga y preparación de los datos

Se descargaron las bases de datos reales *Wine Quality* del repositorio UCI Machine Learning, que contienen mediciones químicas de vinos tintos y blancos. A cada conjunto se le añadió una variable indicadora del tipo de vino (`red` o `white`) y luego ambos fueron combinados en un único conjunto de datos. La variable *type* se trató como un factor, ya que representa los grupos para la clasificación.

4.2 Cálculo de parámetros teóricos por grupo

Se separó el conjunto en dos matrices independientes:

$$X_r : \ vinostintos, \qquad X_w : \ vinosblancos.$$

Para cada grupo se calcularon los parámetros necesarios para implementar el Análisis Discriminante Cuadrático (QDA):

- Vector de medias: μ_r y μ_w
- Matrices de covarianza: S_r y S_w
- Probabilidades a priori:

$$\pi_r = \frac{n_r}{n_r + n_w}, \qquad \pi_w = \frac{n_w}{n_r + n_w}$$

Los valores obtenidos fueron:

$$\pi_{red} = 0.2461, \qquad \pi_{white} = 0.7539.$$

4.3 Selección de una observación a clasificar

Se seleccionó una observación real del conjunto de datos (la primera fila), cuyos once valores representan las mediciones químicas de un vino desconocido. El objetivo es determinar si dicha observación corresponde a un vino tinto o blanco.

fixed acidity	7.4	**density**	0.9978
volatile acidity	0.700	**pH**	3.51
citric acid	0.00	**sulphates**	0.56
residual sugar	1.9	**alcohol**	9.4
chlorides	0.076	**quality**	5
free sulfur dioxide	11	**type**	red
total sulfur dioxide	34		

4.4 Aplicación de la fórmula teórica del QDA

Se implementó la función discriminante cuadrática descrita en el documento teórico:

$$Q_i(x) \ = \ \ln(\pi_i) - \frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}\,(x-\mu_i)'\Sigma_i^{-1}(x-\mu_i),$$

donde $|\Sigma_i|$ es el determinante de la matriz de covarianza del grupo i y $(x-\mu_i)'\Sigma_i^{-1}(x-\mu_i)$ corresponde a la distancia de Mahalanobis.

Se calcularon los valores:

$$Q_{red} = 8.178954, \qquad Q_{white} = -24.82744.$$

Como $Q_{red} > Q_{white}$, la clasificación obtenida mediante la fórmula teórica fue:

$$Clasificación final : TINTO.$$

4.5 Validación con el modelo `qda()` de R

Para verificar los resultados, se ajustó un modelo QDA utilizando todas las observaciones disponibles. El tipo de vino se predijo para cada instancia y se comparó con su valor real.

La matriz de confusión fue:

Real	**Predicho red**	**Predicho white**
red	1582	17
white	77	4821

La exactitud global del modelo fue:

$$Exactitud = 0.9855.$$

Este resultado confirma que QDA es un método adecuado para este conjunto de datos, ya que los vinos tintos y blancos presentan matrices de covarianza distintas, justificando el uso de fronteras cuadráticas en lugar de lineales (LDA).

4.6 Visualización de las fronteras de decisión

Para ilustrar gráficamente las fronteras de clasificación, se ajustó un modelo QDA empleando únicamente las variables alcohol y densidad:

El gráfico Figure 1, muestra la frontera de decisión del modelo QDA en el plano formado por alcohol y densidad. El fondo coloreado indica la región en que el modelo clasificaría un vino como tinto (rosado) o como blanco (azul). Los puntos corresponden a datos reales y las elipses representan la variabilidad de cada grupo. La frontera es curva, lo cual refleja que los vinos tienen matrices de covarianza distintas; esta es la razón por la cual QDA es más apropiado que LDA para este problema.

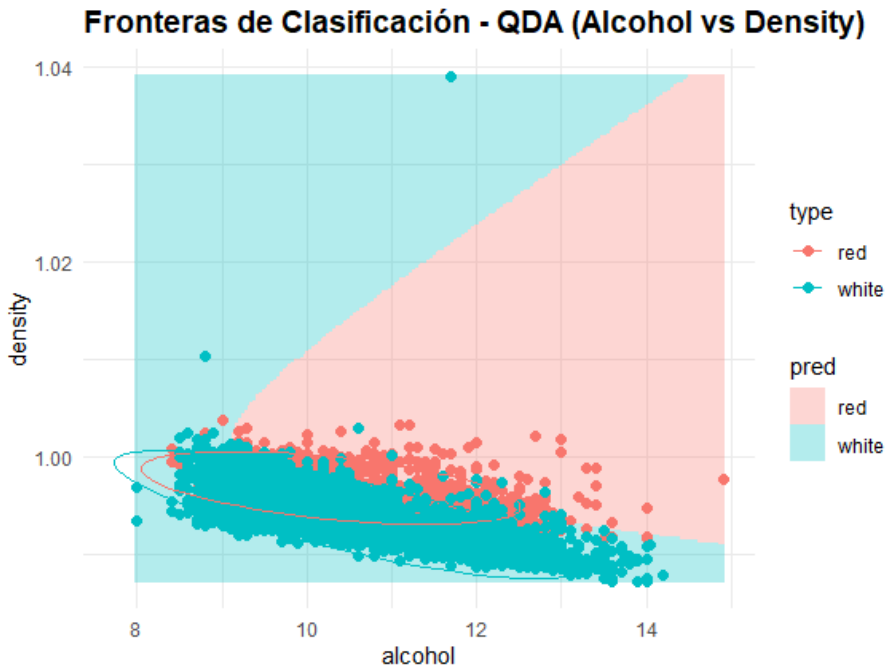


Figure 1: Clasificación de vino

La visualización de las fronteras de decisión confirmó que las diferencias entre las matrices de covarianza de los grupos justifican el uso de QDA para este problema.

5 Conclusión

En este trabajo se explicó el Análisis Discriminante Cuadrático (QDA) desde su fundamento teórico hasta su implementación práctica en un conjunto de datos real, destacando el papel de las matrices de covarianza específicas por grupo y las implicaciones de este supuesto en la forma de las fronteras de decisión.

El estudio aplicado con la base de datos *Wine Quality* mostró que las características fisicoquímicas de los vinos tintos y blancos presentan estructuras de variabilidad distintas, lo que justifica el uso de QDA por encima del modelo lineal (LDA). La visualización de las regiones de decisión confirmó gráficamente la separación entre clases.

A pesar de los buenos resultados, el método QDA presenta ciertas limitaciones que deben considerarse. En primer lugar, la estimación de una matriz de covarianza por cada grupo implica un alto número de parámetros, especialmente cuando la dimensionalidad es elevada; esto puede producir modelos inestables si el número de observaciones no es suficiente o si hay colinealidad entre las variables.

References

[1] Peña, D. (2002). *Análisis de Datos Multivariantes*. McGraw-Hill Interamericana, Madrid.

[2] Rencher, A. C. (2002). *Methods of Multivariate Analysis* (2nd ed.). John Wiley & Sons, New York.

[3] Díaz Monroy, L. G., & Morales Rivera, M. A. (2020). *Estadística multivariada: inferencia y métodos*. Universidad Nacional de Colombia, Bogotá.

[4] Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6th ed.). Pearson Prentice Hall.

[5] Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4), 547–553. Dataset disponible en UCI Machine Learning Repository: *Wine Quality Data Set*. University of California, Irvine.

[6] R Core Team. (2024). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. Disponible en `https://www.R-project.org/`

[7] OpenAI. (2025). *ChatGPT (versión GPT-5.1): Asistencia en análisis estadístico y generación de explicaciones*. Disponible en `https://chat.openai.com/`