Análisis de Atributos de Jugadores de Fútbol del videojuego FIFA de EA Sports temporadas 2008 a 2016

Paula Camila Garcia Nieto

Marzo 2025

1 Selección y Exploración de Datos

1.1 Descripción de la Base de Datos y selección de variables

Se escogió la base de datos "European Soccer Database" de Kaggle, con los datos de jugadores europeos en el videojuego FIFA de EA Sports de las temporadas de los años 2008 a 2016. La base de datos tiene información de Países, Ligas, Partidos, Jugadores, Atributos de jugadores, Equipos y Atributos de equipos.

En este caso, se tomaron la información de las tablas de Jugadores y Atributos de jugadores, de las cuales se omitieron los resultados de las variables relacionadas a los arqueros resultando la información de 183.978 jugadores.

1.2 Estadísticas Descriptivas

1.2.1 Resumen Estadístico de Atributos

Table 1: Atributos técnicos y físicos

Atributo	**Media**	**Mediana**	**Desv. Est.**	**Mínimo**	**Máximo**
Calificación General	68.60	69	7.04	33	94
Potencial	73.46	74	6.59	39	97
Precisión de Centros	55.09	59	17.24	1	95
Definición	49.92	53	19.04	1	97
Precisión de Cabeceo	57.27	60	16.49	1	98
Pase Corto	62.43	65	14.19	3	97
Voleas	49.47	52	18.26	1	93
Regate	59.18	64	17.74	1	97
Curva	52.97	56	18.26	2	94
Precisión de Tiros Libres	49.38	50	17.83	1	97
Pase Largo	57.07	59	14.39	3	97
Control de Balón	63.39	67	15.20	5	97
Aceleración	67.66	69	12.98	10	97
Velocidad	68.05	69	12.57	12	97
Agilidad	65.97	68	12.95	11	96
Reacciones	66.10	67	9.16	17	96
Equilibrio	65.19	67	13.06	12	96
Potencia de Tiro	61.81	65	16.14	2	97
Salto	66.97	68	11.01	14	96
Resistencia	67.04	69	13.17	10	96
Fuerza	67.42	69	12.07	10	96
Tiros Lejanos	53.34	58	18.37	1	96
Agresividad	60.95	64	16.09	6	97
Intercepciones	52.01	57	19.45	1	96
Posicionamiento	55.79	60	18.45	2	96
Visión	57.87	60	15.14	1	97
Penales	55.00	57	15.55	2	96
Marcaje	46.77	50	21.23	1	96
Entrada Normal	50.35	56	21.48	1	95
Barrida	48.00	53	21.60	2	95

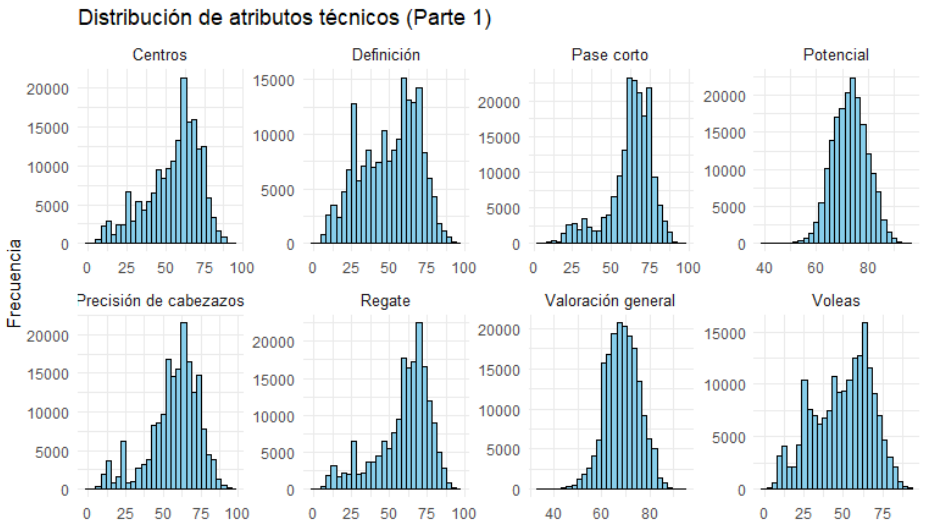


Figure 1: Histogramas de atributos técnicos parte 1

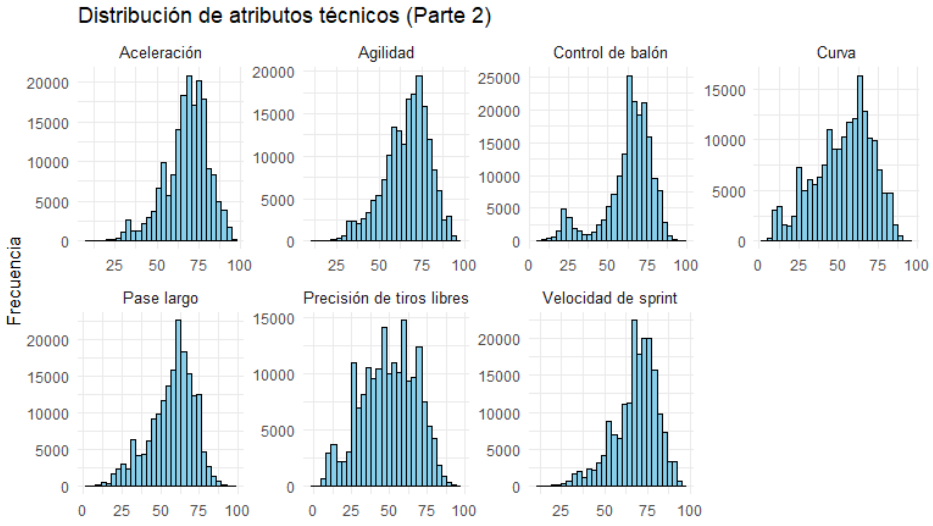


Figure 2: Histogramas de atributos técnicos parte 2

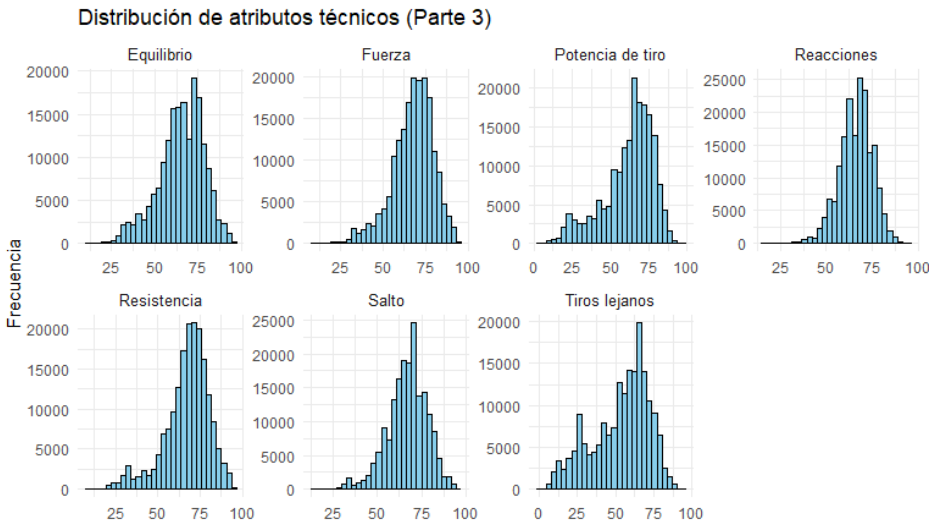


Figure 3: Histogramas de atributos técnicos parte 3

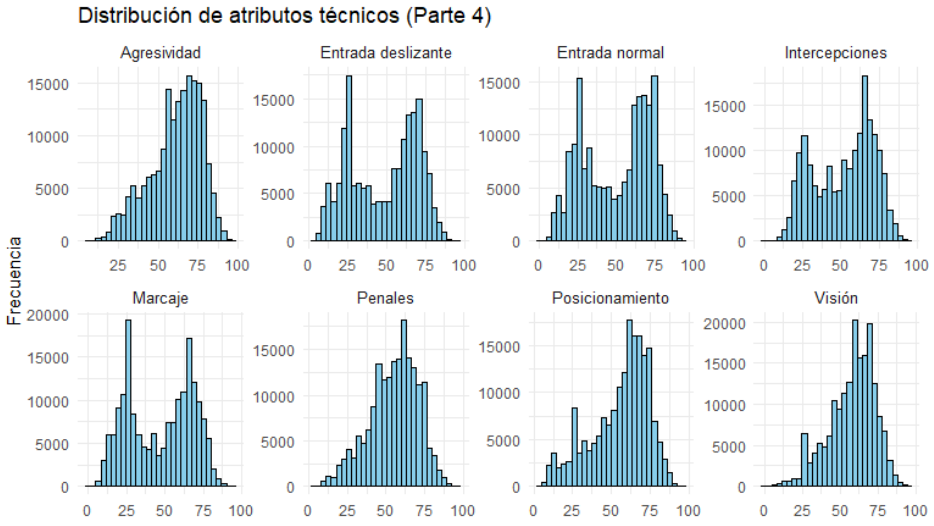


Figure 4: Histogramas de atributos técnicos parte 4

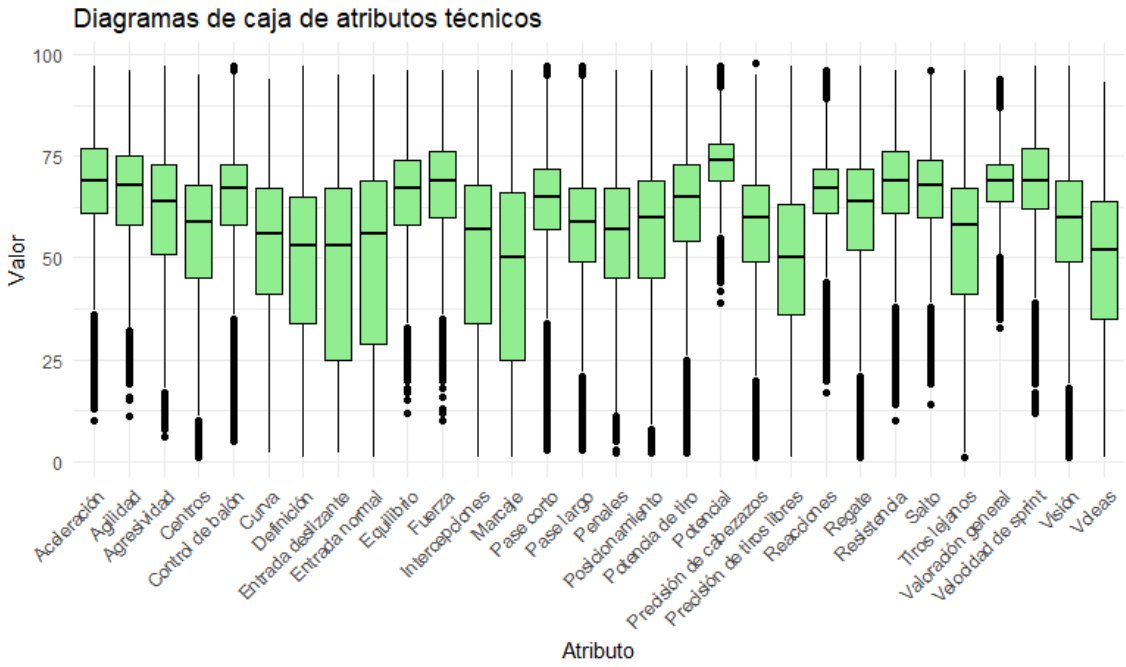


Figure 5: Diagramas de caja de atributos técnicos

1.2.2 Atributos Físicos

Table 2: Peso y altura

Atributo	Media	Mediana	Desv. Est.	Mínimo	Máximo
Peso	168.78	168	15.09	117	243
Altura	181.88	182.88	6.39	157.48	208.28

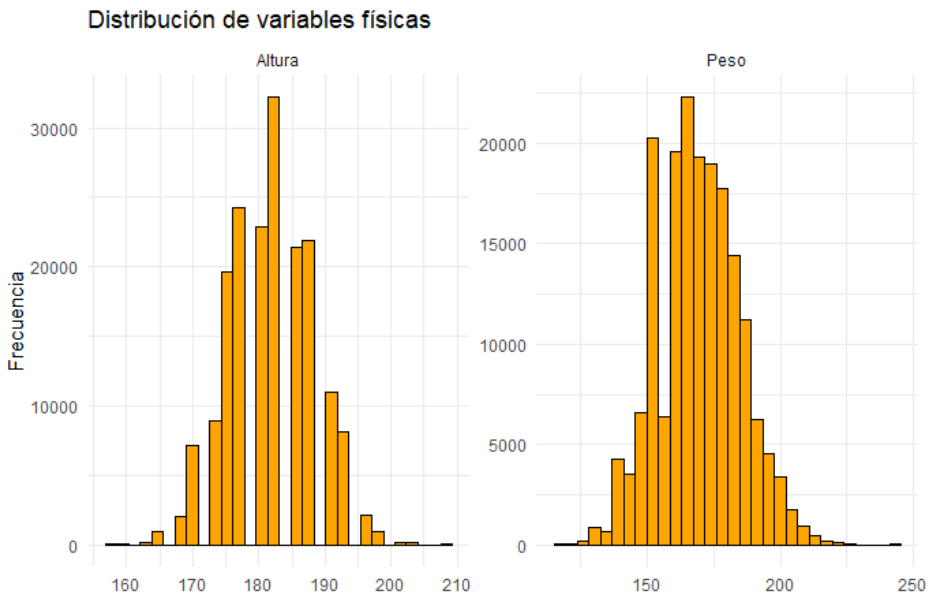


Figure 6: Histogramas de atributos físicos

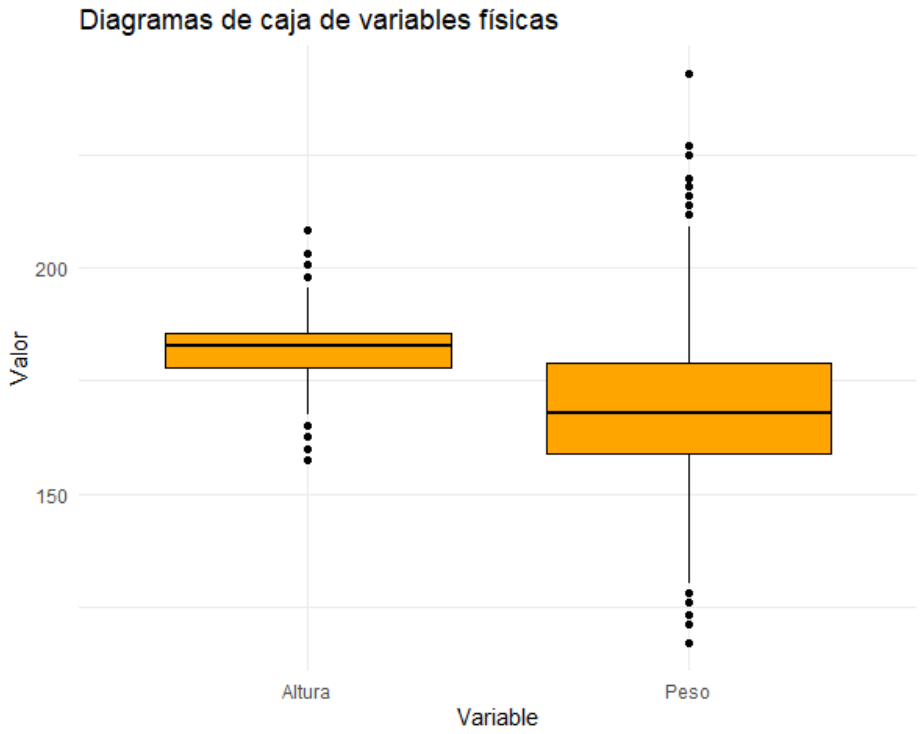


Figure 7: Diagrama de caja de atributos físicos

1.2.3 Resumen Estadístico de Edad

Table 3: Edad

Atributo	Media	Mediana	Desv. Est.	Mínimo	Máximo
Edad	37.47	37	4.85	25	58

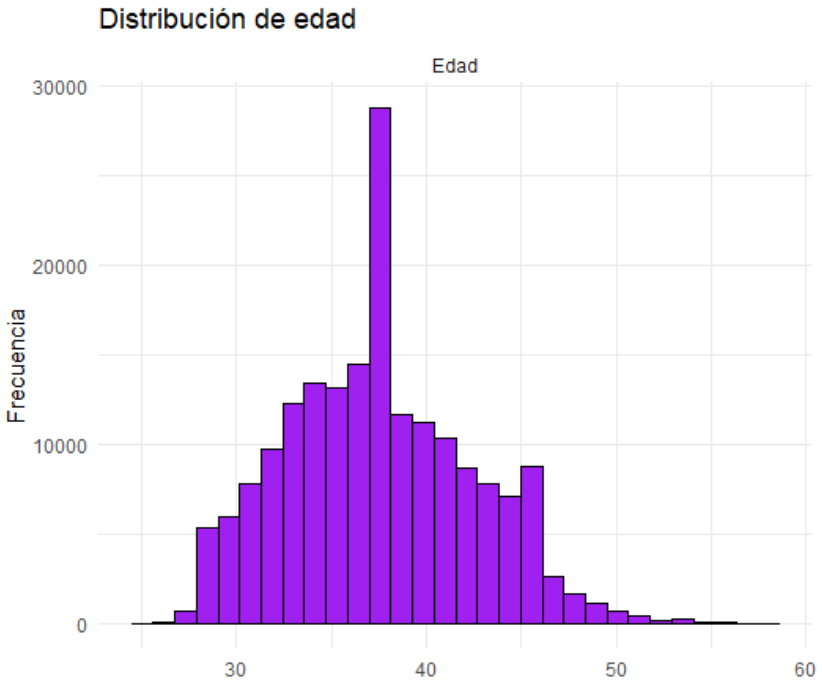


Figure 8: Histograma de edad

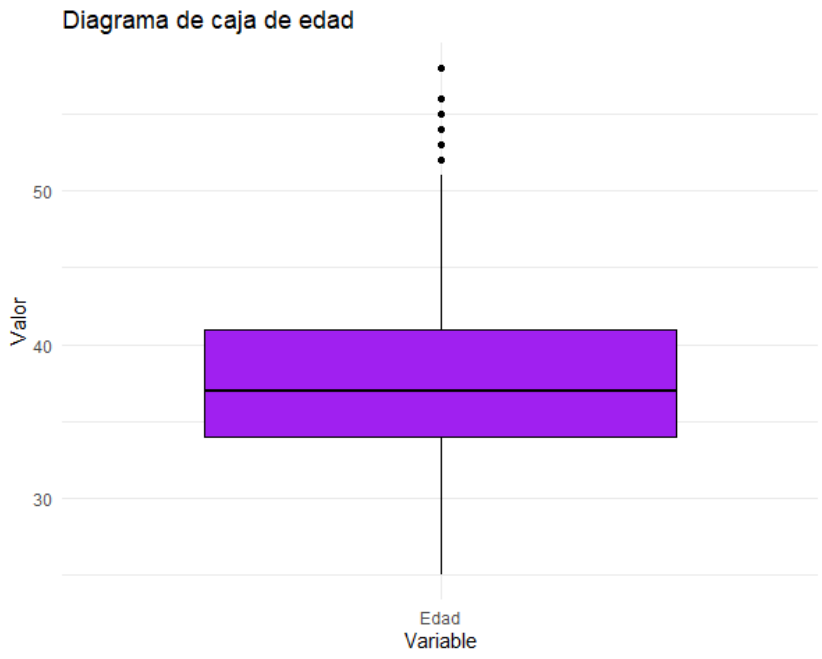


Figure 9: Diagrama de caja de edad

2 Aplicación de Inferencia Estadística

Tenemos dos preguntas:

1. ¿Cómo cambia la calificación general con la edad? Específicamente, si los jugadores de menos de 37 años tienen mejor puntuación en su valoración general a los mayores de 37 años.

2. ¿Hay mayor precisión en los penales hechos por jugadores zurdos? ¿o los diestros?

2.0.1 Visualización de datos en Diagramas de cajas

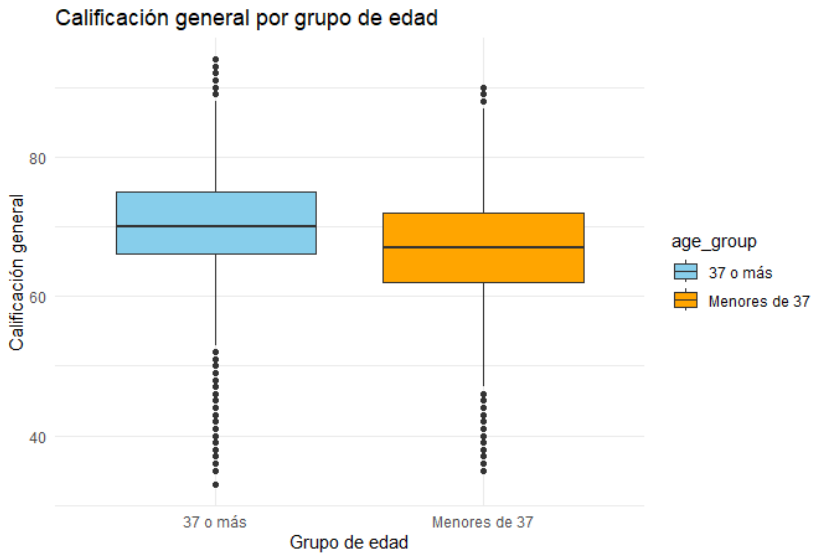


Figure 10: Diagrama de caja de rendimiento por edad

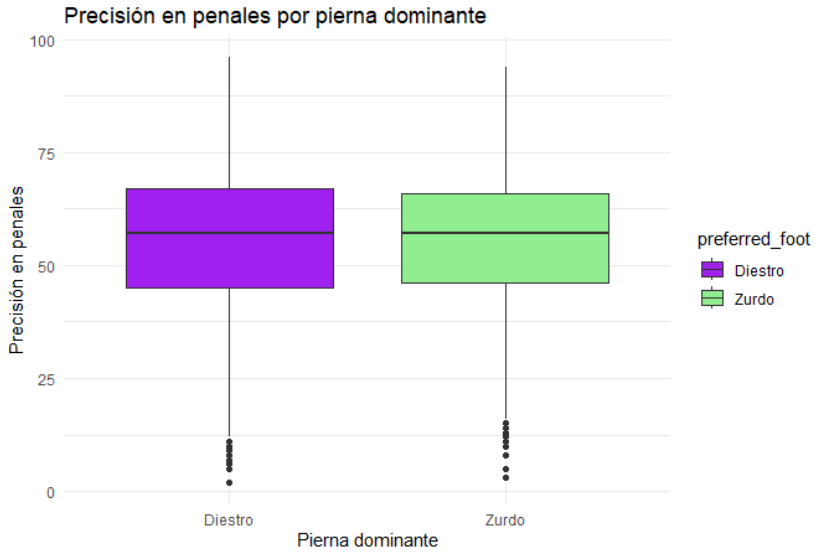


Figure 11: Diagrama de caja de penales por pierna dominante

2.1 Estimación Puntual

2.1.1 Calificación General por Grupo de Edad

Table 4: Calificación general según grupo de edad

Grupo de Edad	Media	Mediana	Desv. Est.	Cantidad
37 o más	70.1	70	6.61	101,202
Menores de 37	66.8	67	7.12	82,776

- **Diferencia en la media:** En el videojuego, los jugadores de 37 años o más tienen una media de 70.1 en la calificación general, mientras que los menores de 37 tienen una media de 66.8. Podriamos decir que los jugadores mayores tienen un mejor rendimiento.
- **Mediana:** Ambas medianas están cerca de la media, lo que indica cierta simetría.

2.1.2 Precisión en Penales por Pierna Dominante

Table 5: Precisión en penales según pierna dominante

Pierna Dominante	Media	Mediana	Desv. Est.	Cantidad
Diestro	54.9	57	15.8	138,409
Zurdo	55.5	57	14.6	44,733

- **Diferencia en la media:** En el videojuego, Los jugadores zurdos tienen una media de precisión de 55.5, 0.6 superior a la de los jugadores diestros, que es de 54.9. Lo que sugiere que no habría diferencia.
- **Mediana:** Ambas medianas son iguales (57), lo que indica que la diferencia en las medias podría deberse a valores extremos.
- **Tamaño de muestra:** La cantidad de jugadores diestros es significativamente mayor (138,409) en comparación con los jugadores zurdos (44,733), lo que podría influir en la interpretación de los resultados ya que al haber muchos más diestros que zurdos, las estimaciones de los diestros son probablemente más precisas.

2.2 Intervalos de Confianza

Vamos a crear un intervalo de confianza (IC) para estimar un rango de valores dentro del cual se encuentra el verdadero valor de un parámetro poblacional con un cierto nivel de confianza, en este caso del 95%.

$$IC = \bar{x} \pm z \cdot \frac{s}{\sqrt{n}}$$

Donde:

- $\bar{x}$ = Media muestral (estimación puntual).
- z = Valor crítico de la distribución normal estándar (para un nivel de confianza del 95%, $z = 1.96$).
- s = Desviación estándar muestral.
- n = Tamaño de la muestra.

Dado que nuestras muestras son muy grandes (183.978 observaciones), podemos aplicar el Teorema Central del Límite (TLC), que establece que, independientemente de la distribución de la población, la distribución muestral de la media se aproxima a una distribución normal conforme el tamaño de la muestra crece. Por esta razón, utilizamos la distribución normal estándar (z) en lugar de la distribución t de Student, que se usa para muestras pequeñas ($n < 30$).

2.2.1 Calificación General por Grupo de Edad

Table 6: Intervalos de confianza para la media de calificación general según grupo de edad

Grupo de Edad	Límite Inferior	Límite Superior
37 o más	70.06	70.14
Menores de 37	66.75	66.85

2.2.2 Precisión en Penales por Pierna Dominante

Table 7: Intervalos de confianza para la media de precisión en penales según pierna dominante

Pierna Dominante	Límite Inferior	Límite Superior
Diestro	54.82	54.98
Zurdo	55.36	55.64

- **Calificación general por grupo de edad:** El intervalo de confianza para los jugadores menores de 37 años es [66.75, 66.85], mientras que para los jugadores de 37 o más es [70.06, 70.14]. Dado que estos intervalos no se cruzan, pueden indicar una diferencia entre las medias siendo la mayor en jugadores mayores a 37 años.
- **Precisión en penales por pierna dominante:** El intervalo de confianza para jugadores diestros es [54.82, 54.98] y para jugadores zurdos es [55.36, 55.64]. Viendo los intervalos, estos tampoco se cruzan, lo que indica que los jugadores zurdos pueden ser mejores cobrando penales.

2.3 Pruebas de Hipótesis

Para las pruebas de hipótesis, usaremos pruebas de dos colas basadas en la distribución normal estándar, gracias al Teorema Central del Límite.

2.3.1 Prueba de Diferencia de Medias: Calificación General por Edad

- H_0: No hay diferencia en la media de calificación general entre jugadores menores de 37 años y mayores de 37 años.
- H_1: Existe una diferencia en la media de calificación general entre ambos grupos.

El estadístico de prueba es:

$$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Donde:

- $\bar{x}_1$, $\bar{x}_2$ = Medias muestrales de cada grupo.

- s_1^2, s_2^2 = Varianzas muestrales.
- n_1, n_2 = Tamaños de muestra.

Resultados:

$$z = 103.19, \quad p < 0.0001$$

Dado el valor p extremadamente pequeño, rechazamos H_0, concluyendo que hay una diferencia significativa en la calificación general entre ambos grupos de edad.

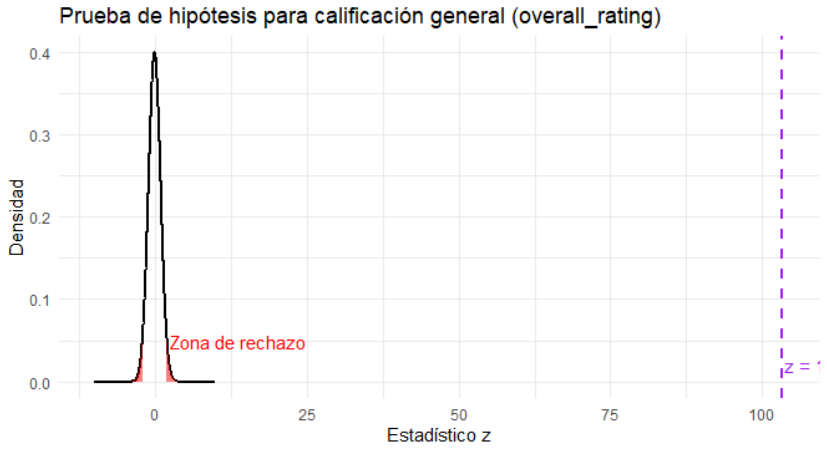


Figure 12: Región de rechazo

2.3.2 Prueba de Diferencia de Medias: Precisión en Penales por Pierna Dominante

- H_0: No hay diferencia en la precisión en penales entre jugadores diestros y zurdos.
- H_1: Existe una diferencia en la precisión en penales entre ambos grupos.

Resultados:

$$z = 7.55, \quad p < 0.0001$$

Rechazamos H_0, indicando una diferencia significativa en la precisión en penales entre diestros y zurdos.

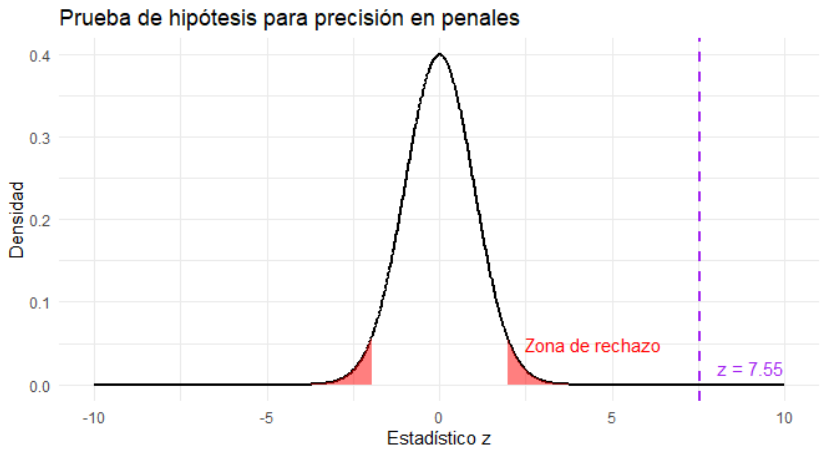


Figure 13: Región de rechazo

3 Simulaciones

Se realizan simulaciones para evaluar la precisión de las estimaciones y la cobertura de los intervalos de confianza mediante la generación repetida de muestras aleatorias.

3.1 Simulación de Estimación de Parámetros

3.1.1 Simulación para la Calificación General

- Distribución de la Media Muestral:

  Generamos 1000 muestras aleatorias del tamaño $n = 100$ de la variable *Calificación General* y calculamos la media muestral en cada una. La distribución resultante de estas medias muestrales es aproximadamente normal, como predice el Teorema Central del Límite.

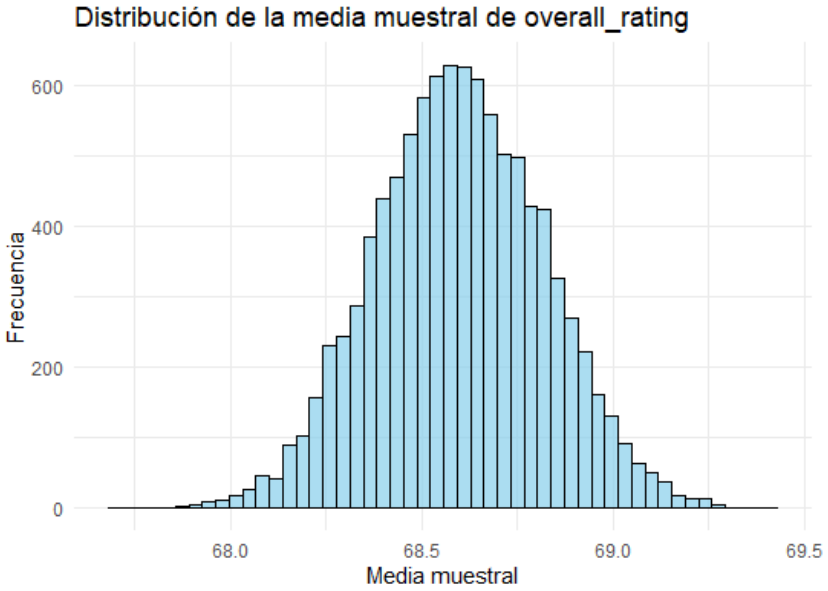


Figure 14: Distribución de la media muestral de Calificación General

- Distribución de la Desviación Estándar Muestral

  De las mismas muestras simuladas, calculamos la desviación estándar muestral. La distribución resultante muestra una ligera asimetría, lo que es común en la estimación de medidas de dispersión, pero se concentra alrededor de la verdadera desviación estándar poblacional.

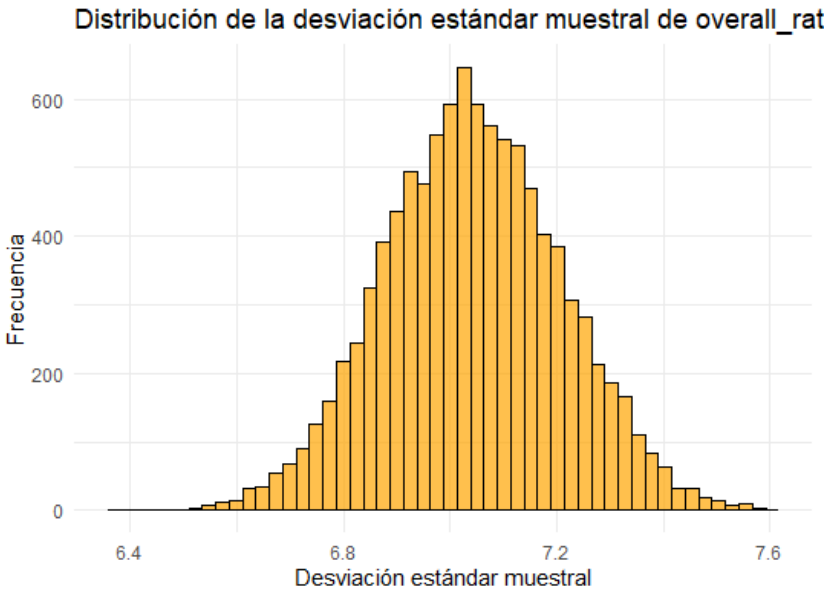


Figure 15: Distribución de la desviación estándar muestral de Calificación General

3.1.2 Simulación para la Precisión en Penales

- Distribución de la Media Muestral

  Repetimos el procedimiento con la variable *penalties*, generando 1000 muestras aleatorias y calculando la media muestral en cada una.

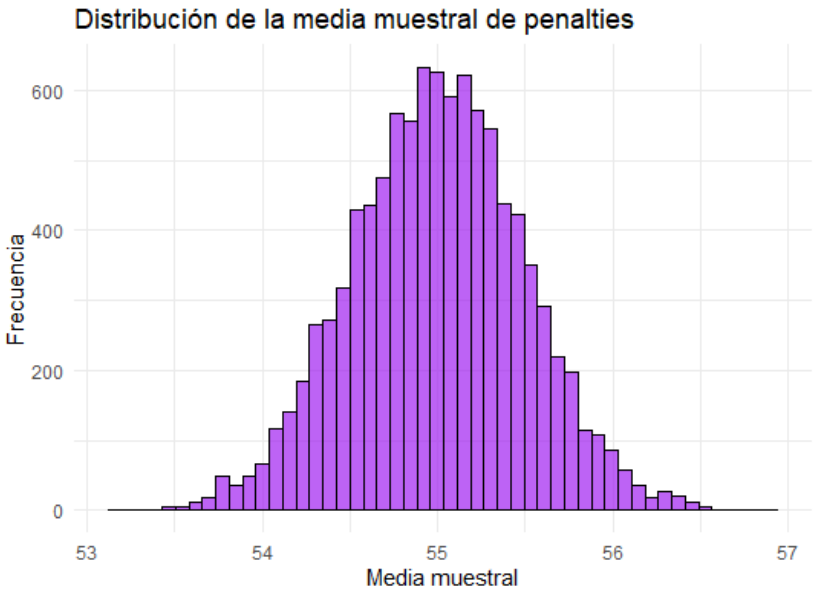


Figure 16: Distribución de la media muestral de Precisión en Penales

- Distribución de la Desviación Estándar Muestral

  Finalmente, obtenemos la distribución de la desviación estándar muestral para *penalties*, que presenta una forma similar a la de *Calificación General*.

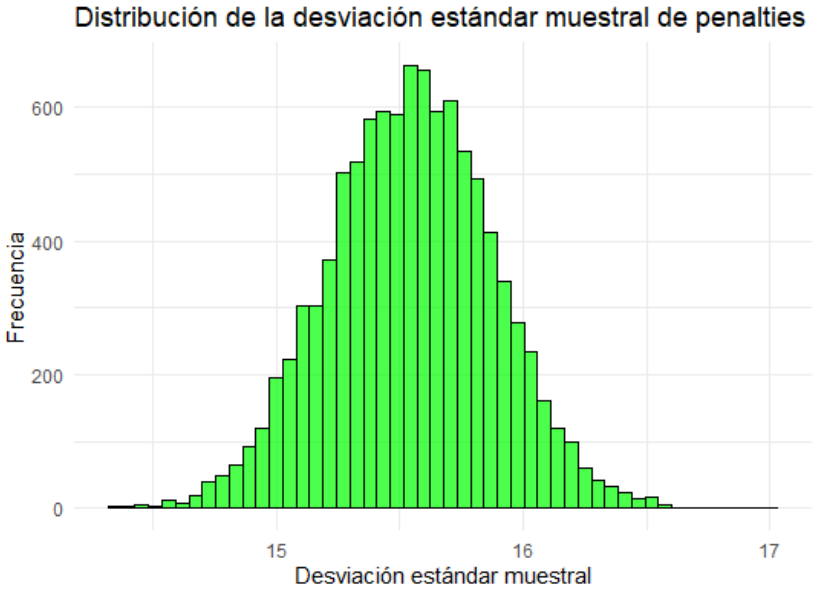


Figure 17: Distribución de la desviación estándar muestral de Precisión en Penales

Las simulaciones muestran que las medias muestrales tienden a ser estimadores insesgados y eficientes. Un estimador es insesgado cuando su valor esperado coincide con el verdadero valor del parámetro poblacional, lo que implica que en promedio no sistematiza errores. Por otro lado, un estimador es eficiente si tiene la menor varianza posible entre todos los estimadores insesgados, lo que se traduce en mayor precisión en las estimaciones. En este caso, las medias muestrales están centradas en la verdadera media poblacional, mientras que las desviaciones estándar presentan una ligera asimetría.

3.2 Simulación de Intervalos de Confianza

La simulación de intervalos de confianza nos permite evaluar la precisión y cobertura de los estimadores muestrales, como la media, mediante la construcción repetida de intervalos a partir de diferentes muestras aleatorias. Esto nos ayuda a verificar si, en el largo plazo, los intervalos construidos contienen el verdadero parámetro poblacional en la proporción esperada.

- Simulación para la Calificación General

  Para la construcción de Intervalos de Confianza, generamos 1000 muestras aleatorias del tamaño $n = 100$ de la variable *Calificación General*

y, para cada muestra, construimos un intervalo de confianza del 95% para la media poblacional. La fórmula utilizada es:

$$IC = \left[\bar{x} - z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}\right]$$

donde $\bar{x}$ es la media muestral, s es la desviación estándar muestral, n es el tamaño de la muestra y $z_{\alpha/2}$ es el valor crítico.

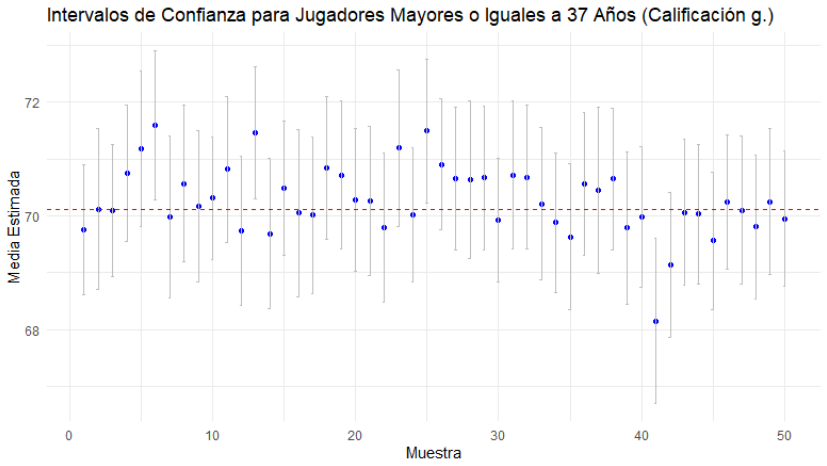


Figure 18: Intervalos de Confianza para la Calificación General igual o menor a 37 años

Cobertura de los intervalos de confianza para jugadores mayores o iguales a 37 años en calificación general: 93.8%

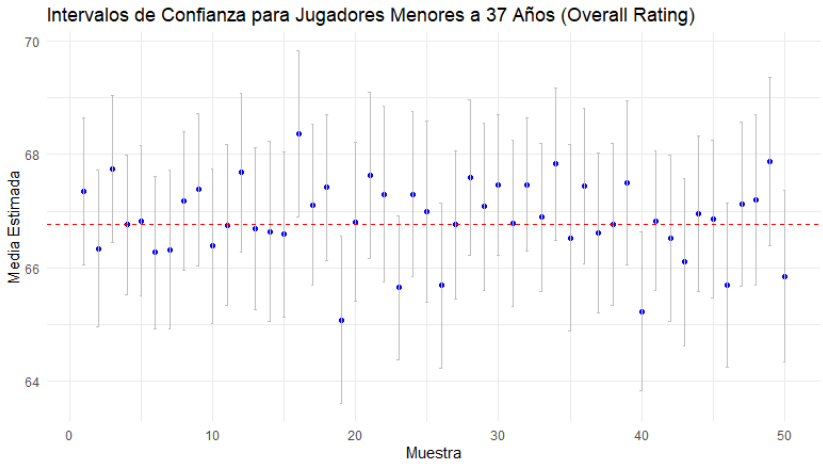


Figure 19: Intervalos de Confianza para la Calificación General menores a 37 años

Cobertura de los intervalos de confianza para jugadores menores a 37 años en calificación general: 93.9 %

- Simulación para precisión en penales por pierna dominante.

  Utilizamos el mismo método para la precisión en penales por cada grupo de jugadores divididos en pierna dominante.

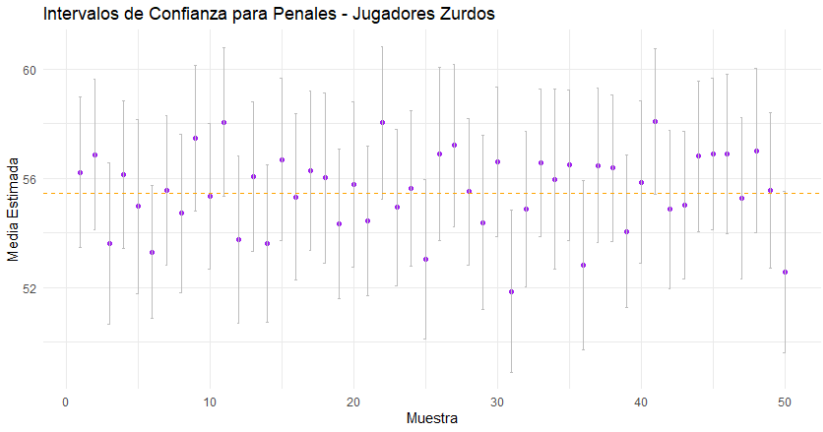


Figure 20: Intervalos de Confianza para la precisión en penales por zurdos

Cobertura de los intervalos de confianza para jugadores zurdos en penales: 95.4%

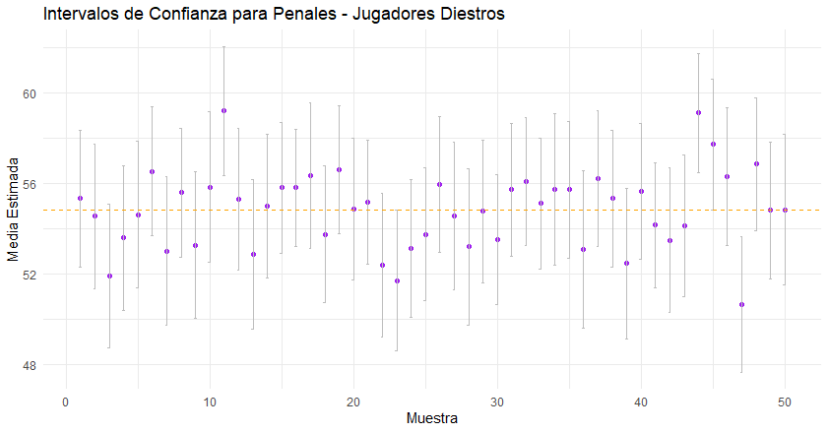


Figure 21: Intervalos de Confianza para la precisión en penales por diestros

Cobertura de los intervalos de confianza para jugadores diestros en penales: 94.6%

Para ambos casos, los resultados muestran que, en las simulaciones, la mayoría de los intervalos de confianza generados contienen la media estimada para cada situación.

3.3 Simulación de Pruebas de Hipótesis

Para esta parte, tenemos que:

Hipótesis nula (H0): Las medias de los dos grupos son iguales.

Hipótesis alternativa (H1): Las medias de los dos grupos son diferentes.

En cada simulación, se calculó el valor p y se determinó si se rechazaba o no la hipótesis nula, según el valor de p.

- Simulación para la Calificación General

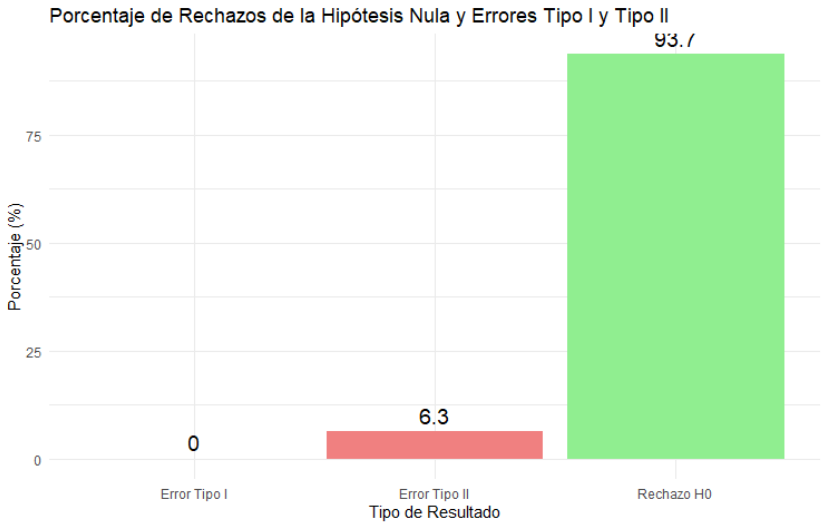


Figure 22: Simulación de pruebas de hipotesis para Calificación general

Los resultados de la simulación muestran que el error tipo II es del 6.3%, lo que indica que en la mayoría de las simulaciones se rechazó correctamente la hipótesis nula (H_0). Esto sugiere que la prueba tiene una buena potencia, lo que significa que las diferencias entre las medias de los grupos (jugadores menores y mayores de 37 años) fueron detectadas adecuadamente. Además, el 93.7% de las veces se rechazó la hipótesis nula, lo que indica que hubo suficiente evidencia para afirmar que las medias de calificación general entre los dos grupos son diferentes. Este porcentaje elevado de rechazo de H_0 indica que la edad tiene un efecto relevante sobre el rendimiento de los jugadores.

- Simulación para precisión en penales por pierna dominante

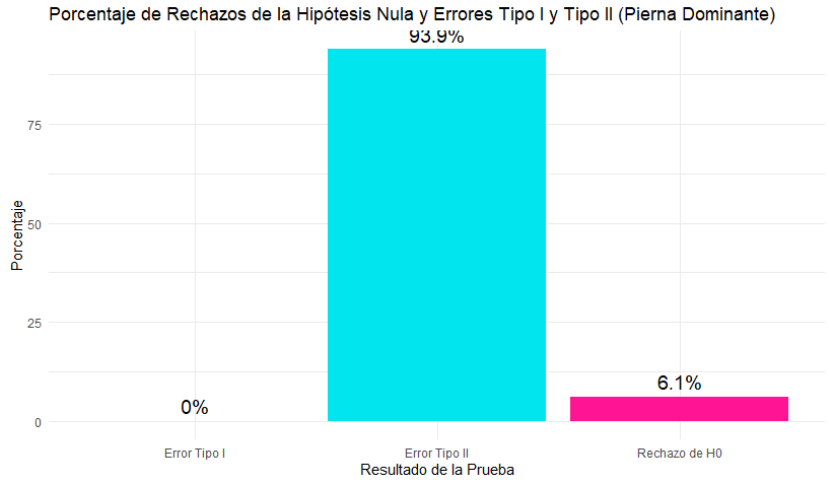


Figure 23: Simulación de pruebas de hipotesis para penales por pierna dominante

Los resultados de la simulación muestran que el error tipo II es del 93.9%, lo que indica que en la mayoría de las simulaciones no se rechazó la hipótesis nula (H_0) cuando las medias de los dos grupos realmente deberían haber sido diferentes. Este alto error tipo II puede deberse a una alta variabilidad dentro de los grupos o a un tamaño de muestra insuficiente. En este contexto, el alto porcentaje de error tipo II indica que la prueba tiene baja potencia, lo que sugiere que la diferencia entre las medias de los grupos es pequeña, o que el tamaño de muestra no es adecuado para detectar diferencias significativas.

4 Referencia

@Base de datos: author = Hugo Mathien, title = European Soccer Database, year = 2025, note = Disponible en: `https://www.kaggle.com/datasets/`,